

4.1 Introducció

A la lliçó anterior, vam veure que els codis binaris sense prefix permeten representar una font sense errors. Però, quin és el codi òptim en termes d'eficiència, és a dir, el que minimitza la longitud mitjana?

Considerem una font U que pren valors a $\{1, \dots, r\}$ amb distribució de probabilitat $\{p_1, \dots, p_r\}$. Per trobar el codi font sense prefix binari que minimitzi la longitud mitjana

$$L_{av} = \sum_{j=1}^r p_j \ell_j, \quad (4.1)$$

si les probabilitats s'ordenen com

$$p_1 \geq p_2 \geq \dots \geq p_r, \quad (4.2)$$

aleshores el codi òptim ha d'escollir una distribució de longituds $\{\ell_1, \ell_2, \dots, \ell_r\}$ tal que

$$\ell_1 \leq \ell_2 \leq \dots \leq \ell_r. \quad (4.3)$$

Qualsevol altra opció dona com a resultat un codi subòptim en termes de longitud mitjana! Els codis que compleixen aquesta condició són els **codis de Huffman**.

Fins ara, la nostra representació en arbre dels codis font només ha tingut en compte l'alfabet de la font i la longitud de les paraules codi. Ara incorporem les probabilitats de la font per derivar els codis òptims. Un arbre de probabilitats amb arrel és un arbre amb un nombre finit de nodes, amb probabilitats assignades a cada node i fulla, de manera que la probabilitat d'un node és la suma de les probabilitats dels seus nodes fills, i l'arrel té probabilitat igual a 1. La figura 4.1 il·lustra un possible arbre de probabilitats




Figura 4.1: Exemple d'arbre de probabilitats amb arrel.

4.2 Codis de Huffman

Els codis de Huffman, inventats per David Huffman quan era estudiant de doctorat al MIT a la dècada de 1950, són els codis òptims, que es poden descriure mitjançant 3 passos elementals. Considerem una font discreta amb valors $\{1, \dots, r\}$ i probabilitats $\{p_1, \dots, p_r\}$. Per determinar un codi de Huffman:

1. Crear r fulles corresponents als símbols r i ordenar-los en probabilitat decreixent.
2. Fusionar els 2 nodes menys probables en un nou node, etiquetat amb la suma de probabilitat.
3. Tornar al pas 1 fins arribar a l'arrel.

Vegem un exemple.




Figura 4.2: Construcció d'un codi de Huffman per a l'Exemple 4.1.

Exemple 4.1. Dissenyem el codi font òptim per a una font que pren valors a $\{a, b, c, d, e\}$ amb distribució de probabilitat $\{0.4, 0.2, 0.2, 0.1, 0.1\}$. Comencem escrivint les $r = 5$ fulles corresponents als símbols en probabilitat decreixent, com a la Figura 4.2(a). Després fusionem els 2 nodes menys probables en un nou node, etiquetat amb probabilitat $0.1 + 0.1 = 0.2$ com a la Figura 4.2(b). Ara, repetim el procediment però amb els nodes que encara no tenen pare. Els 2 nodes menys probables són els que tenen probabilitat 0.2, per tant, es fusionen en un nou node com a la Figura 4.2(c). En aquest punt, podem escollir fusionar el node de probabilitat sense pares 0.2 amb la fulla de probabilitat 0.4 o el node amb la mateixa probabilitat creat al pas anterior. Escollim la segona opció com a la Figura 4.2(d), creant un nou node de probabilitat 0.6. L'últim pas de la figura 4.2(e) dóna com a resultat l'arbre binari amb arrel. Només resta etiquetar l'arbre binari com vam fer a la lliçó anterior i obtenir el codi lliure de prefix $\{0, 10, 110, 1110, 111\}$ per a la font $\{a, b, c, d, e\}$, com a la Figura 4.2(f). El codi de Huffman que hem obtingut no té prefixos, per la qual cosa és descodificable de forma única, amb distribució de longituds $\{1, 2, 3, 4, 4\}$. Quan s'usa per representar la font U , la seva longitud mitjana és

$$L_{av} = 1 \cdot 0,4 + 2 \cdot 0,2 + 3 \cdot 0,2 + 4 \cdot 0,1 + 4 \cdot 0,1 = 2,2 \quad (4.4)$$

bits per símbol. Hi ha punts en l'algorisme on és possible agrupar nodes de manera diferent. En aquest cas, el codi serà diferent, però seguirà tenint la mateixa longitud mitjana!

Problema 4.2. Trobeu un codi de Huffman per a la font de l'Exemple 4.1 amb una distribució de longitud diferent de $\{1, 2, 3, 4, 4\}$.

Solució: Seguim els mateixos passos que a la Figura 4.2(a)–(c), però al pas següent, combinem les dues fulles de probabilitats 0.4 i 0.2 en un nou node de probabilitat 0.6, i seguim l'algorisme per obtenir l'arbre binari de la Figura 4.3. El codi sense prefix obtingut és $\{00, 01, 10, 110, 111\}$, amb distribució de longituds $\{2, 2, 2, 3, 3\}$ i, encara que el codi té una distribució de longituds diferent de l'obtinguda a l'exemple 4.1, la longitud mitjana segueix sent, en bits per símbol:

$$L_{av} = 2 \cdot 0.4 + 2 \cdot 0.2 + 2 \cdot 0.2 + 3 \cdot 0.1 + 3 \cdot 0.1 = 2.2. \quad (4.5)$$

Problema 4.3. Quina és la longitud mitjana del codi de Huffman per a una font que pren valors a $\{a, b, c\}$ amb distribució de probabilitat $\{p, p, 1 - 2p\}$ on $0 < p < \frac{1}{2}$?




Figura 4.3: Arbre binari del Problema 4.2.

Solució: Si $0 < p < \frac{1}{3}$, aleshores a i b són els símbols menys probables i l'algorisme de Huffman condueix a una distribució de longitud $\{2, 2, 1\}$, per exemple, el codi $\{10, 11, 0\}$. En aquest cas $L_{av} = 1 + 2p$. Si $p = \frac{1}{3}$, els tres símbols tenen la mateixa probabilitat, aleshores $\{1, 2, 2\}$, $\{2, 1, 2\}$ i $\{2, 2, 1\}$ són possibles distribucions de longitud, i $L_{av} = \frac{5}{3}$. Si $\frac{1}{3} < p < \frac{1}{2}$, aleshores c és el node menys probable i la distribució de longituds després de la codificació de Huffman és $\{1, 2, 2\}$ o $\{2, 1, 2\}$ i $L_{av} = 2 - p$.

El anàlisi de la longitud mitjana dels codis de Huffman, encara que òptims, és difícil i, en particular, expressar-lo en funció de l'entropia de la font. Suposem que poguéssim construir un codi per a una font U , que pren valors a l'alfabet $\{1, \dots, r\}$ amb probabilitats $\{p_1, \dots, p_r\}$ tals que les longituds de les paraules codi satisfacin exactament $\ell_j = \log_2 \frac{1}{p_j}$. En general, això és difícil, ja que les longituds resultants no són nombres enters. No obstant això, si fóssim capaços de fer-ho, aleshores $L_{av} = \sum_{j=1}^r p_j \ell_j = \sum_{j=1}^r p_j \log_2 \frac{1}{p_j} = -\sum_{j=1}^r p_j \log_2 p_j = H(U)$; la longitud esperada és igual a l'entropia! Òbviament, aquest seria el millor codi. Atès que, en general, ℓ_j no són necessàriament nombres enters, considerem ara el següent

$$\ell_j = \left\lceil \log_2 \frac{1}{p_j} \right\rceil \quad (4.6)$$

on $\lceil x \rceil$ és l'enter més petit més gran o igual a x , que satisfà

$$\log_2 \frac{1}{p_j} \leq \ell_j < \log_2 \frac{1}{p_j} + 1. \quad (4.7)$$

Usant la desigualtat del costat esquerre a (4.7), tenim que es compleix la desigualtat de Kraft:

$$\sum_{j=1}^r 2^{-\ell_j} \leq \sum_{j=1}^r 2^{-\log_2 \frac{1}{p_j}} = \sum_{j=1}^r p_j = 1, \quad (4.8)$$

cosa que implica que existeix un codi sense prefix binari amb aquestes longituds. Atès que el codi de Huffman condueix a la longitud mitjana més petita possible, es dedueix que

$$L_{av} \leq \sum_{j=1}^r p_j \ell_j \quad (4.9)$$

$$= \sum_{j=1}^r p_j \left\lceil \log_2 \frac{1}{p_j} \right\rceil \quad (4.10)$$

$$< \sum_{j=1}^r p_j \left(\log_2 \frac{1}{p_j} + 1 \right) \quad (4.11)$$

$$= H(U) + 1, \quad (4.12)$$

on a (4.11) usem la desigualtat del costat dret a (4.7). Per tant, podem concloure que la longitud mitjana L_{av} del codi òptim per a una font U , donada per la codificació de Huffman, satisfà

$$H(U) \leq L_{av} < H(U) + 1, \quad (4.13)$$

on $H(U)$ és l'entropia de la font.

Problema 4.4. Considerem una font discreta sense memòria U que pren valors sobre $\{a, b\}$ amb distribució $\{\frac{1}{3}, \frac{2}{3}\}$. Trobeu el codi òptim per a U , calculeu la longitud mitjana i comproveu que es compleix la desigualtat (4.13).




Figura 4.4: Arbre binari de probabilitats del Problema 4.5.

Solució: En aquest cas, el codi de Huffman resultant és $\{0,1\}$ o $\{1,0\}$, de distribució de longituds $\{1,1\}$ i longitud mitjana $L_{av} = 1$ bits per símbol. L'entropia en aquest cas és $H(U) = -\sum_{j=1}^r p_j \log_2 p_j = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3} \approx 0.918296$, i per tant $0.918296 \leq L_{av} < 1.918296$.

Problema 4.5. Considerem dos símbols consecutius (U_1, U_2) d'una font discreta sense memòria on cada U_i es descriu com al Problema 4.4. Trobeu el codi òptim per a (U_1, U_2) , calculeu la longitud mitjana per símbol i verifiqueu que es compleix la desigualtat (4.13). Compareu els vostres resultats amb els del Problema 4.4.

Solució: Primer construïm l'alfabet i la distribució de probabilitat per a (U_1, U_2) . L'alfabet és el producte cartesià $\{a, b\} \times \{a, b\} = \{aa, ab, ba, bb\}$ i, atès que els símbols són iid, la distribució de probabilitat és $\{\frac{1}{9}, \frac{2}{9}, \frac{2}{9}, \frac{4}{9}\}$. Després d'ordenar les probabilitats i seguint l'algorisme de Huffman, obtenim l'arbre binari de la Figura 4.4. Un possible codi de Huffman és aleshores $\{111, 110, 10, 0\}$, de longituds $\{3, 3, 2, 1\}$ i longitud mitjana

$$L_{av} = 3 \cdot \frac{1}{9} + 3 \cdot \frac{2}{9} + 2 \cdot \frac{2}{9} + 1 \cdot \frac{4}{9} = \frac{17}{9} \approx 1.88889 \quad (4.14)$$

bits per a dos símbols font. En aquest cas, l'entropia de (U_1, U_2) ve donada per

$$H(U_1, U_2) = -\sum_{j=1}^r p_j \log_2 p_j = -\frac{1}{9} \log_2 \frac{1}{9} - \frac{2}{9} \log_2 \frac{2}{9} - \frac{2}{9} \log_2 \frac{2}{9} - \frac{4}{9} \log_2 \frac{4}{9} \approx 1.83659.$$

Per tant, (4.13) es compleix com s'esperava perquè $1.83659 \leq L_{av} < 2.83659$. Comparat amb el codi de Huffman del problema 4.4, observem que el codi de Huffman $\{111, 110, 10, 0\}$ té una longitud mitjana de 1.88889 bits per codificar dos símbols font, cosa que correspon a una longitud mitjana de $\frac{1.88889}{2} = 0.944444$ bits per símbol, lleugerament menor que 1.

Al Problema 4.5 hem vist que podem fer-ho millor si codifiquem blocs de símbols d'una font discreta sense memòria en lloc de codificar un sol símbol. El benefici augmenta si trobem codis per a seqüències font llargues $(U_1, \dots, U_n)$ com $n \rightarrow \infty$. Aquest és el tema de la nostra propera lliçó.