

4.1 Introducción

En la lección anterior, vimos que los códigos binarios sin prefijos permiten representar una fuente sin errores. Pero, ¿cuál es el código óptimo en términos de eficiencia, es decir, el que minimiza la longitud media?

Consideremos una fuente U que toma valores en $\{1, \dots, r\}$ con distribución de probabilidad $\{p_1, \dots, p_r\}$. Para encontrar el código fuente sin prefijo binario que minimice la longitud promedio

$$L_{av} = \sum_{j=1}^r p_j \ell_j, \quad (4.1)$$

si las probabilidades se ordenan como

$$p_1 \geq p_2 \geq \dots \geq p_r, \quad (4.2)$$

entonces el código óptimo debe elegir una distribución de longitudes $\{\ell_1, \ell_2, \dots, \ell_r\}$ tal que

$$\ell_1 \leq \ell_2 \leq \dots \leq \ell_r. \quad (4.3)$$

¡Cualquier otra opción da como resultado un código subóptimo en términos longitud promedio! Los códigos que cumplen tal condición son los **códigos de Huffman**.

Hasta ahora, nuestra representación en árbol de los códigos de fuente solo ha tenido en cuenta el alfabeto de la fuente y la longitud de las palabras código. Ahora incorporamos las probabilidades de la fuente para derivar los códigos óptimos. Un árbol de probabilidades con raíz es un árbol un número finito de nodos, con probabilidades asignadas a cada nodo y hoja, de modo que la probabilidad de un nodo es la suma de las probabilidades de sus nodos hijos, y la raíz tiene probabilidad igual a 1. La figura 4.1 ilustra un posible árbol de probabilidades




Figura 4.1: Ejemplo de árbol de probabilidades con raíz.

4.2 Códigos de Huffman

Los códigos de Huffman, inventados por David Huffman cuando era estudiante de doctorado en el MIT en la década de 1950, son los códigos óptimos, que se pueden describir mediante 3 pasos elementales. Consideremos una fuente discreta con valores $\{1, \dots, r\}$ y probabilidades $\{p_1, \dots, p_r\}$. Para determinar un código de Huffman:

1. Crear r hojas correspondientes a los símbolos r y ordenarlos en probabilidad decreciente.
2. Fusionar los 2 nodos menos probables en un nuevo nodo, etiquetado con la suma de probabilidad.
3. Volver al paso 1 hasta llegar a la raíz.

Veamos un ejemplo.




Figura 4.2: Construcción de un código de Huffman para el Ejemplo 4.1.

Ejemplo 4.1. Diseñemos el código fuente óptimo para una fuente tomando valores en $\{a, b, c, d, e\}$ con distribución de probabilidad $\{0,4, 0,2, 0,2, 0,1, 0,1\}$. Empezamos escribiendo las $r = 5$ hojas correspondientes a los símbolos en probabilidad decreciente, como en la Figura 4.2(a). Luego fusionamos los 2 nodos menos probables en un nuevo nodo, etiquetado con probabilidad $0,1 + 0,1 = 0,2$ como en la Figura 4.2(b). Ahora, repetimos el procedimiento pero con los nodos que aún no tienen padre. Los 2 nodos menos probables son los que tienen probabilidad 0,2, por lo tanto, se fusionaron en un nuevo nodo como en la Figura 4.2(c). En este punto, podemos elegir fusionar el nodo de probabilidad sin padres 0,2 con la hoja de probabilidad 0,4 o el nodo con la misma probabilidad creado en el paso anterior. Elegimos la segunda opción como en la Figura 4.2(d), creando un nuevo nodo de probabilidad 0,6. El último paso de la figura 4.2(e) da como resultado el árbol binario con raíz. Solo resta etiquetar el árbol binario como hicimos en la lección anterior y obtener el código libre de prefijos $\{0, 10, 110, 1110, 111\}$ para la fuente $\{a, b, c, d, e\}$, como en la Figura 4.2(f). El código de Huffman que obtuvimos no tiene prefijos, por lo que es decodificable de forma única, con distribución de longitudes $\{1, 2, 3, 4, 4\}$. Cuando se usa para representar la fuente U , su longitud promedio es

$$L_{av} = 1 \cdot 0,4 + 2 \cdot 0,2 + 3 \cdot 0,2 + 4 \cdot 0,1 + 4 \cdot 0,1 = 2,2 \quad (4.4)$$

bits por símbolo. Hay puntos en el algoritmo, es posible agrupar nodos de manera distinta. En este caso, el código será diferente, ¡pero seguirá teniendo la misma longitud promedio!

Problema 4.2. Encuentre un código de Huffman para la fuente en el Ejemplo 4.1 con una distribución de longitud distinta a $\{1, 2, 3, 4, 4\}$.

Solución: Seguimos los mismos pasos que en la Figura 4.2(a)–(c), pero en el siguiente paso, combinamos las dos hojas de probabilidades 0,4 y 0,2 en un nuevo nodo de probabilidad 0,6, y seguimos el algoritmo para obtener el árbol binario de la Figura 4.3. El código sin prefijo obtenido es $\{00, 01, 10, 110, 111\}$, con distribución de longitudes $\{2, 2, 2, 3, 3\}$ y, aunque el código tiene una distribución de longitudes distinta a la obtenida en el ejemplo 4.1, la longitud media sigue siendo, en bits por símbolo:

$$L_{av} = 2 \cdot 0,4 + 2 \cdot 0,2 + 2 \cdot 0,2 + 3 \cdot 0,1 + 3 \cdot 0,1 = 2,2. \quad (4.5)$$




Figura 4.3: Árbol binario del Problema 4.2.

Problema 4.3. ¿Cuál es la longitud promedio del código de Huffman para una fuente que toma valores en $\{a, b, c\}$ con distribución de probabilidad $\{p, p, 1 - 2p\}$ donde $0 < p < \frac{1}{2}$?

Solución: Si $0 < p < \frac{1}{3}$, entonces a y b son los símbolos menos probables y el algoritmo de Huffman conduce a una distribución de longitud $\{2, 2, 1\}$, por ejemplo, el código $\{10, 11, 0\}$. En este caso $L_{av} = 1 + 2p$. Si $p = \frac{1}{3}$, los tres símbolos tienen la misma probabilidad, entonces $\{1, 2, 2\}$, $\{2, 1, 2\}$ y $\{2, 2, 1\}$ son posibles distribuciones de longitud, y $L_{av} = \frac{5}{3}$. Si $\frac{1}{3} < p < \frac{1}{2}$, entonces c es el nodo menos probable y la distribución de longitudes después de la codificación de Huffman es $\{1, 2, 2\}$ o $\{2, 1, 2\}$ y $L_{av} = 2 - p$.

El análisis de la longitud media de los códigos de Huffman, aunque óptimos, es difícil y, en particular, expresarlo en función de la entropía de la fuente. Supongamos que pudiéramos construir un código para una fuente U , tomando valores en el alfabeto $\{1, \dots, r\}$ con probabilidades $\{p_1, \dots, p_r\}$ tales que las longitudes de las palabras código satisfagan exactamente $\ell_j = \log_2 \frac{1}{p_j}$. En general, esto es difícil, ya que las longitudes resultantes no son números enteros. Sin embargo, si fuéramos capaces de hacer esto, entonces $L_{av} = \sum_{j=1}^r p_j \ell_j = \sum_{j=1}^r p_j \log_2 \frac{1}{p_j} = -\sum_{j=1}^r p_j \log_2 p_j = H(U)$; ¡la longitud esperada es igual a la entropía! Obviamente, este sería el mejor código. Dado que, en general, ℓ_j no son necesariamente números enteros, consideremos ahora lo siguiente

$$\ell_j = \left\lceil \log_2 \frac{1}{p_j} \right\rceil \quad (4.6)$$

donde $\lceil x \rceil$ es el entero más pequeño mayor o igual a x , que satisface

$$\log_2 \frac{1}{p_j} \leq \ell_j < \log_2 \frac{1}{p_j} + 1. \quad (4.7)$$

Usando la desigualdad del lado izquierdo en (4.7), tenemos que se cumple la desigualdad de Kraft:

$$\sum_{j=1}^r 2^{-\ell_j} \leq \sum_{j=1}^r 2^{-\log_2 \frac{1}{p_j}} = \sum_{j=1}^r p_j = 1, \quad (4.8)$$

lo que implica que existe un código sin prefijo binario con estas longitudes. Dado que el código de Huffman conduce a la longitud promedio más pequeña posible, se deduce que

$$L_{av} \leq \sum_{j=1}^r p_j \ell_j \quad (4.9)$$

$$= \sum_{j=1}^r p_j \left\lceil \log_2 \frac{1}{p_j} \right\rceil \quad (4.10)$$

$$< \sum_{j=1}^r p_j \left(\log_2 \frac{1}{p_j} + 1 \right) \quad (4.11)$$

$$= H(U) + 1, \quad (4.12)$$

donde en (4.11) usamos la desigualdad del lado derecho en (4.7). Por tanto, podemos concluir que la longitud media L_{av} del código óptimo para una fuente U , dada por la codificación de Huffman, satisface

$$H(U) \leq L_{av} < H(U) + 1, \quad (4.13)$$

donde $H(U)$ es la entropía de la fuente.




Figura 4.4: Árbol binario de probabilidades del Problema 4.5.

Problema 4.4. Considere una fuente discreta sin memoria U que toma valores sobre $\{a, b\}$ con distribución $\{\frac{1}{3}, \frac{2}{3}\}$. Encuentre el código óptimo para U , calcule la longitud promedio y compruebe que se cumple la desigualdad (4.13).

Solución: En este caso, el código de Huffman resultante es $\{0, 1\}$ o $\{1, 0\}$, de distribución de longitudes $\{1, 1\}$ y longitud media $L_{av} = 1$ bits por símbolo. La entropía en este caso es $H(U) = -\sum_{j=1}^r p_j \log_2 p_j = -\frac{1}{3} \log_2 \frac{1}{3} - \frac{2}{3} \log_2 \frac{2}{3} \approx 0,918296$, y por lo tanto $0,918296 \leq L_{av} < 1,918296$.

Problema 4.5. Considere dos símbolos consecutivos (U_1, U_2) de una fuente discreta sin memoria donde cada U_i se describe como en el Problema 4.4. Encuentre el código óptimo para (U_1, U_2) , calcule la longitud promedio por símbolo y verifique que se cumpla la desigualdad (4.13). Compare sus resultados con los del Problema 4.4.

Solución: Primero construimos el alfabeto y la distribución de probabilidad para (U_1, U_2) . El alfabeto es el producto cartesiano $\{a, b\} \times \{a, b\} = \{aa, ab, ba, bb\}$ y, dado que los símbolos son iid, la distribución de probabilidad es $\{\frac{1}{9}, \frac{2}{9}, \frac{2}{9}, \frac{4}{9}\}$. Después de ordenar las probabilidades y siguiendo el algoritmo de Huffman, obtenemos el árbol binario de la Figura 4.4. Un posible código de Huffman es entonces $\{111, 110, 10, 0\}$, de longitudes $\{3, 3, 2, 1\}$ y longitud media

$$L_{av} = 3 \cdot \frac{1}{9} + 3 \cdot \frac{2}{9} + 2 \cdot \frac{2}{9} + 1 \cdot \frac{4}{9} = \frac{17}{9} \approx 1,88889 \quad (4.14)$$

bits para dos símbolos fuente. En este caso, la entropía de (U_1, U_2) viene dada por

$$H(U_1, U_2) = -\sum_{j=1}^r p_j \log_2 p_j = -\frac{1}{9} \log_2 \frac{1}{9} - \frac{2}{9} \log_2 \frac{2}{9} - \frac{2}{9} \log_2 \frac{2}{9} - \frac{4}{9} \log_2 \frac{4}{9} \approx 1,83659.$$

Por tanto, (4.13) se cumple como se esperaba porque $1,83659 \leq L_{av} < 2,83659$. Comparado con el código de Huffman del problema 4.4, observamos que el código de Huffman $\{111, 110, 10, 0\}$ tiene una longitud promedio de 1,88889 bits para codificar dos símbolos fuente, lo que corresponde a una longitud promedio de $\frac{1,88889}{2} = 0,944444$ bits por símbolo, ligeramente menor que 1.

En el Problema 4.5 hemos visto que podemos hacerlo mejor si codificamos bloques de símbolos de una fuente discreta sin memoria en lugar de codificar un solo símbolo. El beneficio aumenta si encontramos códigos para secuencias fuente largas $(U_1, \dots, U_n)$ como $n \rightarrow \infty$. Este es el tema de nuestra próxima lección.