

Tema 5. Límites fundamentales en compresión de fuente

5.1 Introducción

Hasta ahora, hemos visto que los códigos Huffman son los códigos óptimos para cualquier fuente discreta y que la longitud media L_{av} de este código está “cerca” de la entropía de la fuente. En otras palabras, el código óptimo para una fuente U que toma valores en $\{1, \dots, r\}$ con distribución de probabilidad $\{p_1, \dots, p_r\}$ satisface

$$H(U) \leq L_{\text{av}} < H(U) + 1, \quad (5.1)$$

donde $L_{\text{av}} = \sum_{j=1}^r \ell_j p_j$ es la longitud media del código y $H(U) = -\sum_{j=1}^r p_j \log_2 p_j$ es la entropía de la fuente. En el tema anterior, encontramos que el rendimiento del código óptimo aumentaba comprimiendo varios símbolos a la vez. Es decir, podemos diseñar nuestro código Huffman para bloques de n símbolos $X = (U_1, \dots, U_n)$ y obtener un código cuya longitud media satisfaga

$$H(X) \leq L_{\text{av}} < H(X) + 1. \quad (5.2)$$

Calcular la entropía $H(X)$ puede ser complicado, ya que la cardinalidad del alfabeto de X crece exponencialmente con n . Es decir, el número de posibles secuencias fuente de longitud n , dado por n veces el producto cartesiano del alfabeto, es r^n . Sin embargo, si la fuente no tiene memoria, el cálculo de $H(X)$ se simplifica bastante.

5.2 Entropía de una fuente discreta sin memoria

Consideremos una fuente descrita por la secuencia de variables aleatorias $X = (U_1, \dots, U_n)$ tomando valores en

$$\mathcal{X} = \mathcal{U}^n = \underbrace{\mathcal{U} \times \dots \times \mathcal{U}}_{n \text{ veces}} \quad (5.3)$$

con distribución conjunta $P_X(x) = P_{U_1 \dots U_n}(u_1, \dots, u_n)$. La entropía de X viene dada por el valor esperado del logaritmo negativo de la distribución conjunta, es decir

$$H(X) = \mathbb{E} \left[\log_2 \frac{1}{P_X(X)} \right] = - \sum_{x \in \mathcal{X}} P_X(x) \log_2 P_X(x). \quad (5.4)$$

Como la fuente no tiene memoria, $X = (U_1, \dots, U_n)$ es una secuencia de variables independientes y, por tanto, la distribución de X cumple

$$P_X(x) = \prod_{i=1}^n P_{U_i}(u_i). \quad (5.5)$$

Utilizando (5.5) en (5.4) obtenemos que


$$H(X) = -\mathbb{E} \left[\log_2 \prod_{i=1}^n P_{U_i}(U_i) \right] = -\mathbb{E} \left[\sum_{i=1}^n \log_2 P_{U_i}(U_i) \right] = \sum_{i=1}^n \mathbb{E} \left[\log_2 \frac{1}{P_{U_i}(U_i)} \right] = \sum_{i=1}^n H(U_i); \quad (5.6)$$

la entropía de una secuencia de variables aleatorias independientes resulta ser la suma de cada entropía individual. Finalmente, como en una fuente discreta sin memoria los símbolos están distribuidos de manera idéntica, todas las entropías son iguales y

$$H(X) = nH(U); \quad (5.7)$$

la entropía de una secuencia de variables i.i.d. aleatorias es n veces la entropía de un solo símbolo!

Problema 5.1. Una fuente discreta $X = (U_1, \dots, U_n)$ produce símbolos independientes U_i , todos tomando valores sobre el alfabeto $\{0, 1\}$. La entropía de X viene dada por la siguiente gráfica en función de n .



¿Cuál de las afirmaciones siguientes es cierta?

- (a) La fuente no tiene memoria (U_i son independientes y se distribuyen de manera idéntica para $i = 1, \dots, n$)
- (b) U_1 y U_3 tienen símbolos equiprobables
- (c) $H(U_2) = 1$
- (d) La longitud media de cualquier código binario sin prefijo para X con $n = 3$ cumple $L_{av} \geq 3$

Solución: Utilizando (5.6) y a partir de la gráfica, inferimos que $H(U_1) = 1$, $H(U_1) + H(U_2) = 1$ y $H(U_1) + H(U_2) + H(U_3) = 2$, implicando $H(U_2) = 0$ y $H(U_3) = 1$. Como $H(U_2) = 0$, la fuente no puede tener memoria (en realidad solo si $H(U_1) = H(U_2) = H(U_3)$) invalidando (a) y (c). La entropía de X para $n = 3$ es $H(X) = 2$, por tanto, la longitud media de cualquier código binario sin prefijo para esta fuente está limitada por 2, no por 3. Finalmente, (b) es cierta porque tanto U_1 como U_3 toman valores en $\{0, 1\}$ y, para bits equiprobables, $H(U_1)$ y $H(U_3)$ son efectivamente iguales a 1.

5.3 Comprimiendo una fuente de información

Ahora estamos equipados para demostrar el rendimiento asintótico de comprimir una fuente de información X con códigos binarios sin prefijo óptimos (Huffman) cuando la longitud de los bloques fuente codificados n tiende a infinito. Para ello, definimos la longitud media por símbolo como

$$L_n = \frac{L_{av}}{n}, \quad (5.8)$$

donde L_{av} es la longitud media del código óptimo (Huffman) para una fuente discreta sin memoria $X = (U_1, \dots, U_n)$. De la misma manera, definimos la eficiencia de un código utilizado para representar una fuente X de longitud n como

$$e_n = \frac{H(X)}{L_{av}}. \quad (5.9)$$

Si la fuente no tiene memoria, entonces $H(X) = nH(U)$ y la eficiencia se puede escribir utilizando la longitud media por símbolo L_n en (5.8) como

$$e_n = \frac{nH(U)}{L_{av}} = \frac{nH(U)}{nL_n} = \frac{H(U)}{L_n}. \quad (5.10)$$

Ejemplo 5.2. Consideremos la fuente discreta sin memoria $X = (U_1, \dots, U_n)$ donde cada U_i toma valores $\{a, b\}$ con probabilidad $\{\frac{2}{3}, \frac{1}{3}\}$. Para $n = 1$, tenemos $H(X) = H(U) = \log_2(3) - \frac{2}{3}$ bits, mientras que el código óptimo sin prefijo tiene una distribución de longitud $\{1, 1\}$ que conduce a $L_{av} = 1$ bit. Utilizando las ecuaciones (5.8) y (5.10) obtenemos $L_1 = 1$ y una eficiencia de

$$e_1 = \frac{H(X)}{L_{av}} = \frac{H(U)}{L_1} = H(U) = \log_2(3) - \frac{2}{3} \approx 0,918296. \quad (5.11)$$

Para $n = 2$, tenemos que X toma valores en $\{aa, ab, ba, bb\}$ con probabilidad $\{\frac{4}{9}, \frac{2}{9}, \frac{2}{9}, \frac{1}{9}\}$, por tanto una entropía de $H(X) = 2H(U) = 2\log_2(3) - \frac{4}{3}$. El código óptimo sin prefijo para X es, por ejemplo, el código Huffman

$\{0, 10, 110, 111\}$ de la distribución de longitud $\{1, 2, 3, 3\}$, dando una longitud media de $L_{av} = \frac{17}{9}$. Como estamos codificando bloques de $n = 2$ símbolos, la longitud media por símbolo en este caso es de $L_2 = \frac{L_{av}}{2} = \frac{17}{18}$ bits por símbolo. Con estos números, obtenemos una eficiencia de

$$e_2 = \frac{H(X)}{L_{av}} = \frac{2 \log_2(3) - \frac{4}{3}}{17/9} \approx 0,972313, \quad (5.12)$$

ligeramente superior a la de (5.11).

Problema 5.3. Calculad la eficiencia del código óptimo sin prefijo para X en el ejemplo 5.2 para $n = 3$.

Solución: Para determinar la eficiencia e_3 necesitamos la entropía de X por un lado, y la longitud media del código de Huffman para X por el otro. Como la fuente no tiene memoria, no necesitamos calcular todo el alfabeto y la distribución de X para calcular la entropía y simplemente utilizar $H(X) = 3H(U) = 3 \log_2(3) - 2$. Para construir el código Huffman, debemos determinar el alfabeto y la distribución de X . Después de hacerlo, construir el árbol de Huffman y encontrar la distribución de longitud (queda como ejercicio!), obtenemos una longitud media de $L_{av} = \frac{76}{27}$. Por tanto,

$$e_3 = \frac{H(X)}{L_{av}} \approx 0,97871, \quad (5.13)$$

otro aumento de la eficiencia respecto a (5.12).

Problema 5.4. Diseñamos un código sin prefijo subóptimo para la fuente discreta sin memoria X en el ejemplo 5.2. Para cualquier n , las longitudes de este código cumplen $\ell(x) = \lceil -\log_2 P_X(x) \rceil$. Calculad la eficiencia de este código para $n = 3$ y comparadla con la del código óptimo.

Solución: Para $n = 3$, X toma valores en $\{aaa, aab, aba, abb, baa, bab, bba, bbb\}$ con distribución de probabilidad $\{\frac{8}{27}, \frac{4}{27}, \frac{4}{27}, \frac{2}{27}, \frac{4}{27}, \frac{2}{27}, \frac{2}{27}, \frac{1}{27}\}$. La eficiencia del código óptimo ya se calculó en (5.13). El código subóptimo codificará $x = aaa$ con $\ell(x) = \ell(aaa) = \lceil -\log_2 P_X(aaa) \rceil = \lceil -\log_2 \frac{8}{27} \rceil \approx \lceil 1,75489 \rceil = 2$ bits. Con el mismo procedimiento obtenemos una distribución de longitudes $\{2, 3, 3, 4, 3, 4, 4, 5\}$, dando una longitud media de $L_{av} = 3$ y una eficiencia de $e_3 \approx 0,918296$, menor que la óptima.

Hemos visto de los ejercicios anteriores que aumentar n puede aumentar la eficiencia, es decir, que L_{av} se acerca a $H(X)$ o que L_n se acerca a $H(U)$. Para verlo, combinamos los resultados obtenidos en este apartado con los del apartado 5.1. Utilizando (5.8) y (5.7) en (5.2), tenemos que la longitud media por símbolo del código óptimo sin prefijo para una fuente discreta sin memoria X satisface (después de dividir por n todos los términos):

$$H(U) \leq L_n < H(U) + \frac{1}{n}. \quad (5.14)$$

Como L_n tiene límite inferior y superior como en (5.14), concluimos que

$$\lim_{n \rightarrow \infty} L_n = H(U); \quad (5.15)$$

la compresión de bloques es muy eficiente ya que la longitud media correspondiente por símbolo L_n converge a la entropía de la fuente. El mismo resultado se puede expresar en términos de eficiencia. Dado que la longitud media de cualquier código libre de prefijo para X tiene un límite inferior como $L_{av} \geq H(X)$, a partir de la definición de la eficiencia en (5.10) encontramos que la eficiencia tiene un límite superior como $e_n \leq \frac{H(X)}{H(X)} = 1$. De la misma manera, utilizando que la longitud media del código óptimo satisface $L_{av} < H(X) + 1$, tenemos que $e_n > \frac{H(X)}{H(X)+1}$. Combinándolo todo, tenemos

$$\frac{H(X)}{H(X)+1} < e_n \leq 1. \quad (5.16)$$

Si la fuente no tiene memoria, entonces (5.16) se puede escribir como

$$\frac{H(U)}{H(U) + \frac{1}{n}} < e_n \leq 1, \quad (5.17)$$

implicando el resultado siguiente:

$$\lim_{n \rightarrow \infty} e_n = 1. \quad (5.18)$$

Ejemplo 5.5. Consideremos una fuente discreta sin memoria $X = \{U_1, \dots, U_n\}$ donde cada U_i toma valores en $\{a, b, c\}$ con probabilidad $\{\frac{1}{2}, \frac{1}{4}, \frac{1}{4}\}$. La entropía de U es $H(U) = \frac{3}{2}$. Por ejemplo, para $n = 10$, esto implica que la longitud media del código óptimo para X satisface $15 \leq L_{\text{av}} < 16$, o que la longitud media por símbolo satisface $\frac{3}{2} \leq L_{10} < \frac{8}{5}$, o que la eficiencia satisface $\frac{15}{16} < e_{10} \leq 1$.

Finalizamos el último tema sobre la codificación de fuente con un problema relacionado con la probabilidad y el rendimiento asintótico de comprimir una fuente de información.

Problema 5.6. Una fuente discreta sin memoria $X = (U_1, \dots, U_n)$ tiene una distribución de probabilidad $P_X(x)$. Definimos la variable aleatoria $Y = f(X)$, donde $f(x) = -\log_2 P_X(x)$. Calcula $\lim_{n \rightarrow \infty} \mathbb{P}[Y < n^2 H(U)]$.

Solución: Utilizando la desigualdad de Markov, ya que Y es una variable aleatoria no negativa, tenemos que

$$\mathbb{P}[Y < n^2 H(U)] = 1 - \mathbb{P}[Y \geq n^2 H(U)] \geq 1 - \frac{\mathbb{E}[Y]}{n^2 H(U)}. \quad (5.19)$$

El valor esperado de Y se puede calcular en términos de X , dado que $\mathbb{E}[Y] = \mathbb{E}[f(X)] = \mathbb{E}[-\log_2 P_X(X)]$, que resulta ser la definición de la entropía de X según (5.4). Por tanto, $\mathbb{E}[Y] = H(X)$. Como la fuente no tiene memoria, a partir de (5.7), también tenemos que $H(X) = nH(U)$. Combinando todos los resultados, obtenemos

$$1 \geq \mathbb{P}[Y < n^2 H(U)] \geq 1 - \frac{1}{n}, \quad (5.20)$$

donde la primera cota es una cota trivial. Tomando el límite cuando $n \rightarrow \infty$ en todos los términos anteriores, concluimos que $\lim_{n \rightarrow \infty} \mathbb{P}[Y < n^2 H(U)] = 1$.