

9.1 Introducción

A partir de las expresiones de la información mutua $I(X; Y)$ del tema anterior, podemos establecer relaciones entre entropías. Ya que $I(X; Y) = H(Y) - H(Y|X) = H(X) + H(Y) - H(X, Y) = H(X) - H(X|Y)$, despejando $H(X, Y)$ obtenemos

$$H(X, Y) = H(Y|X) + H(X) \quad (9.1)$$

$$= H(X|Y) + H(Y), \quad (9.2)$$

la llamada **regla de la cadena de la entropía**, consecuencia de la regla de la cadena de la probabilidad. Utilizando $P_{XY}(x, y) = P_{Y|X}(y|x)P_X(x)$ y $H(X, Y) = \mathbb{E}[-\log_2 P_{XY}(X, Y)]$, tenemos

$$H(X, Y) = \mathbb{E}[-\log_2 P_{XY}(X, Y)] \quad (9.3)$$

$$= \mathbb{E}[-\log_2 P_{Y|X}(Y|X) - \log_2 P_X(X)] \quad (9.4)$$

$$= \underbrace{\mathbb{E}[-\log_2 P_{Y|X}(Y|X)]}_{H(Y|X)} + \underbrace{\mathbb{E}[-\log_2 P_X(X)]}_{H(X)}. \quad (9.5)$$

La ecuación (9.2) se obtiene de manera similar con $P_{XY}(x, y) = P_{X|Y}(x|y)P_Y(y)$. La regla de la cadena nos dice que la incertidumbre de (X, Y) se descompone como la incertidumbre de X más la incertidumbre residual de Y dado X . Análogamente, $I(X; Y)$ mide la reducción de incertidumbre de Y al conocer X . En esta lección, veremos propiedades de las medidas de información; herramientas utilizadas más allá de las comunicaciones digitales.

9.2 Medidas de información

Como podemos expresar la distribución de probabilidad conjunta de n variables aleatorias $(X_1, \dots, X_n)$ como

$$P_{X_1 \dots X_n}(x_1, \dots, x_n) = P_{X_1}(x_1)P_{X_2|X_1}(x_2|x_1)P_{X_3|X_1 X_2}(x_3|x_1 x_2) \cdots P_{X_n|X_1 \dots X_{n-1}}(x_n|x_1 \dots x_{n-1}) \quad (9.6)$$

podemos escribir la **regla de la cadena de la entropía** en general como

$$H(X_1 \dots X_n) = H(X_1) + H(X_2|X_1) + H(X_3|X_1 X_2) + \cdots + H(X_n|X_1 \dots X_{n-1}). \quad (9.7)$$

Recordemos que la regla de la cadena se puede escribir en cualquier orden, p.ej., $H(X, Y, Z) = H(X) + H(Y|X) + H(Z|YX)$ o $H(X, Y, Z) = H(Y) + H(Z|Y) + H(X|YZ)$. Como el condicionamiento reduce la entropía, $H(X_i|X_1 \dots X_{i-1}) \leq H(X_i)$, y la **entropía conjunta** está acotada por la suma de entropías marginales:

$$H(X_1 \dots X_n) \leq \sum_{i=1}^n H(X_i). \quad (9.8)$$

La cota de (9.8) se alcanza con igualdad cuando $H(X_2|X_1) = H(X_2)$, $H(X_3|X_1 X_2) = H(X_3)$, y así sucesivamente. Sabemos que $H(X_2|X_1) = H(X_2)$ se cumple cuando $P_{X_2|X_1}(x_2|x_1) = P_{X_2}(x_2)$, es decir, cuando X_1 y X_2 son independientes, de modo que conocer X_1 no reduce la incertidumbre sobre X_2 . De forma análoga, $H(X_3|X_1 X_2) = H(X_3)$ se cumple cuando X_3 es independiente de X_1 y X_2 , y así sucesivamente. Concluimos que (9.8) se satisface con igualdad cuando $(X_1, \dots, X_n)$ es una secuencia de variables aleatorias independientes.

El siguiente resultado muestra que aplicar una función determinista a una variable aleatoria no puede aumentar su entropía (véase la figura 9.1). Sean X e Y dos variables aleatorias sobre los alfabetos $\mathcal{X}$ e $\mathcal{Y}$, respectivamente,




Figura 9.1: Salida Y de una función determinista de X .

y supongamos que $Y = g(X)$ donde $g(x)$ es una función determinista, es decir, que no introduce aleatoriedad, como por ejemplo $g(x) = x^2$ o $g(x) = \log_2 p(x)$. Expresando $H(X, Y)$ de dos maneras:

$$H(X, Y) = H(X) + \overbrace{H(Y|X)}^{=0} \quad (9.9)$$

$$= H(Y) + \underbrace{H(X|Y)}_{\geq 0}, \quad (9.10)$$

donde $H(Y|X) = 0$ ya que Y es función determinista de X . Como $H(X|Y) \geq 0$, la entropía de la salida de una **función determinista** cumple

$$H(Y) \leq H(X). \quad (9.11)$$

Es decir, manipular X de manera determinista no puede aumentar su incertidumbre.

Definimos ahora la **información mutua condicional** $I(X; Y|Z)$, la información de X sobre Y conociendo Z :

$$I(X; Y|Z) = \mathbb{E} \left[\log_2 \frac{P_{XY|Z}(X, Y|Z)}{P_{X|Z}(X|Z)P_{Y|Z}(Y|Z)} \right] = \mathbb{E} \left[\log_2 \frac{P_{X|YZ}(X|YZ)}{P_{X|Z}(X|Z)} \right] = \mathbb{E} \left[\log_2 \frac{P_{Y|XZ}(Y|XZ)}{P_{Y|Z}(Y|Z)} \right], \quad (9.12)$$

y en términos de entropías como

$$I(X; Y|Z) = H(Y|Z) - H(Y|XZ) \quad (9.13)$$

$$= H(X|Z) + H(Y|Z) - H(X, Y|Z) \quad (9.14)$$

$$= H(X|Z) - H(X|YZ) \quad (9.15)$$

$$= I(Y; X|Z). \quad (9.16)$$

Estas son las mismas expresiones de la lección 8 con el condicionamiento de Z añadido en todos los términos, y son válidas para cualquier trío de variables aleatorias con distribución conjunta $P_{XYZ}(x, y, z)$.




Figura 9.2: Ilustración de la independencia condicional y el teorema del procesamiento de datos.

En comunicaciones digitales y otras disciplinas, las variables aleatorias X , Y y Z suelen formar parte de una cadena de procesamiento de datos como la de la figura 9.2, donde Y es la salida de un sistema con entrada X , y Z la salida de otro con entrada Y . Esto no implica que Z sea independiente de X , ya que una variación de X puede inducir una variación de Y que a su vez induce una variación de Z . Sin embargo, conocer la variable intermedia Y produce una forma de independencia entre X y Z . Esta es la noción de **cadena de Markov**: X , Y y Z forman una cadena $X \rightarrow Y \rightarrow Z$ si, dada Y , X y Z son independientes:

$$P_{XZ|Y}(x, z|y) = P_{X|Y}(x|y)P_{Z|Y}(z|y). \quad (9.17)$$

En consecuencia, si $X \rightarrow Y \rightarrow Z$ forman una cadena de Markov, tras conocer Y , Z no tiene información sobre X y viceversa, y la información mutua condicional $I(X; Z|Y)$ se anula porque

$$I(X; Z|Y) = \mathbb{E} \left[\log_2 \frac{P_{XZ|Y}(X, Z|Y)}{P_{X|Y}(X|Y)P_{Z|Y}(Z|Y)} \right] = \mathbb{E} \left[\log_2 \frac{P_{X|Y}(X|Y)P_{Z|Y}(Z|Y)}{P_{X|Y}(X|Y)P_{Z|Y}(Z|Y)} \right] = \mathbb{E}[\log_2(1)] = 0. \quad (9.18)$$

Consideremos $I(X; Y, Z) = I(Y, Z; X) = H(Y, Z) - H(Y, Z|X)$. Utilizando $H(Y, Z) = H(Y) + H(Z|Y)$ y $H(Y, Z|X) = H(Y|X) + H(Z|X, Y)$ obtenemos

$$I(Y, Z; X) = H(Y, Z) - H(Y, Z|X) = \underbrace{H(Y) - H(Y|X)}_{I(X; Y)} + \underbrace{H(Z|Y) - H(Z|X, Y)}_{I(X; Z|Y)}; \quad (9.19)$$

esta es la **regla de la cadena de la información mutua**. ¡A diferencia de la entropía, el condicionamiento puede aumentar la información mutua! Análogamente, con $H(Y, Z) = H(Z) + H(Y|Z)$ y $H(Y, Z|X) = H(Z|X) + H(Y|X, Z)$:

$$I(Y, Z; X) = H(Y, Z) - H(Y, Z|X) = \underbrace{H(Z) - H(Z|X)}_{I(X; Z)} + \underbrace{H(Y|Z) - H(Y|X, Z)}_{I(X; Y|Z)}. \quad (9.20)$$

Combinando (9.19) y (9.20):

$$I(X; YZ) = I(X; Y) + \overbrace{I(X; Z|Y)}^{=0} \quad (9.21)$$

$$= I(X; Z) + \underbrace{I(X; Y|Z)}_{\geq 0}, \quad (9.22)$$

donde $I(X; Z|Y) = 0$ por la cadena de Markov e $I(X; Y|Z) \geq 0$. Así, obtenemos el **teorema de procesamiento de datos**: si $X \rightarrow Y \rightarrow Z$ forman una cadena de Markov,

$$I(X; Z) \leq I(X; Y). \quad (9.23)$$

Es decir, procesar datos no puede aumentar la información mutua: la información de Z sobre X no supera la de Y sobre X .

Finalmente, estudiamos $I(X_1 \cdots X_n; Y_1 \cdots Y_n)$ para un **canal discreto sin memoria** con entrada $(X_1, \dots, X_n)$ y salida $(Y_1, \dots, Y_n)$:

$$I(X_1 \cdots X_n; Y_1 \cdots Y_n) = H(Y_1 \cdots Y_n) - H(Y_1 \cdots Y_n | X_1 \cdots X_n) \quad (9.24)$$

$$= H(Y_1 \cdots Y_n) - \sum_{i=1}^n H(Y_i | X_1 \cdots X_n Y_1 \cdots Y_{i-1}) \quad (9.25)$$

$$= H(Y_1 \cdots Y_n) - \sum_{i=1}^n H(Y_i | X_i) \quad (9.26)$$

$$\leq \sum_{i=1}^n H(Y_i) - \sum_{i=1}^n H(Y_i | X_i) \quad (9.27)$$

$$= \sum_{i=1}^n I(X_i; Y_i) \quad (9.28)$$

donde (9.25) es la regla de la cadena, (9.26) usa que el canal no tiene memoria (Y_i solo depende de X_i), y (9.27) viene de (9.8). La igualdad en (9.27) se alcanza cuando $(Y_1, \dots, Y_n)$ son independientes, lo que sugiere que esta es la mejor estrategia para canales sin memoria.